

Research związany z grafowymi sieciami neuronowymi

01.04.2025 odbył się wykład prowadzony przez mgr Roberta Benke dotyczący grafowych sieci neuronowych. Celem było uzyskanie informacji, w jaki sposób można by użyć tego do reprezentacji różnych schematów. Pomogłoby to wtedy w błędach rozpoznawania tych schematów. GNN (Graph Neural Network) mógłby pytać lub podpowiadać, że w danym miejscu powinno być połączenie.

Zadania, jakie mógłby realizować GNN:

- Klasyfikacja wierzchołka (Node Classification) - klasyfikacja nierozpoznanego elementu
- Przewidywanie połączenia (Link prediction) - wykrywanie nierozpoznanych połączeń na schematach

Dlaczego grafowe sieci w tym przypadku będą lepsze niż inne?

Grafowe sieci neuronowe wykorzystują relacje między węzłami, co umożliwia propagację informacji w obrębie całego grafu. Dzięki temu embeddingi poszczególnych węzłów są bardziej precyzyjne i oddają nie tylko cechy samego węzła, ale również wpływ jego otoczenia. W odróżnieniu od standardowych podejść, takich jak konwolucyjne sieci neuronowe, które operują na stałym zbiorze sąsiednich pikseli (np. 8 sąsiadów), grafowe sieci mogą operować na dowolnie rozbudowanym zestawie relacji między elementami.

Dzięki propagacji informacji przez kolejne warstwy, GNN są zdolne do uchwycenia nie tylko bezpośrednich, lokalnych zależności, ale również długodystansowych powiązań pomiędzy elementami systemu. Takie podejście jest szczególnie korzystne przy analizie schematów w elektronice i automatyce, gdzie relacje między komponentami mają często złożony charakter. Integracja cech węzłów z informacjami o ich połączeniach umożliwia lepsze odwzorowanie rzeczywistego systemu, co przekłada się na skuteczniejsze wykrywanie błędów oraz precyzyjniejsze przewidywanie brakujących połączeń.

Podsumowując, grafowe sieci neuronowe dzięki zdolności do modelowania struktury grafu oraz integracji cech poszczególnych elementów systemu mogą oferować lepsze wyniki w zadaniach klasyfikacji węzłów i przewidywania połączeń, co jest szczególnie istotne w zastosowaniach związanych z elektroniką i automatyką.

Problemy:

- duża ilość danych treningowych do uzyskania satysfakcjonujących efektów (trzeba by przerobić wiele schematów na grafy opisując je odpowiednio)
- duże grafy wymagałyby dużej mocy obliczeniowej
- właściwy dobór parametrów (potrzebny by był bardzo dobry research, na który trzeba by poświęcić dużo czasu)
- trudno zrozumieć, które relacje w grafie mają największy wpływ na wyniki, co utrudnia wdrażanie heurystyk dziedzinowych.

Podsumowanie:

Grafowe sieci neuronowe mogą usprawnić działanie rozpoznawania schematów, jednakże wiąże się to z użyciem większej mocy obliczeniowej. Nie wiadomo także czy uzyskamy odpowiednie rezultaty. Najlepsze rozwiązanie to dokładniejszy research, poszukanie danych treningowych (o ile istnieją, ręczne przerabianie to duża ilość pracy) oraz implementacja z obserwacją uzyskiwanych wyników.