



Parsowanie tekstu za pomocą modelu LLaMA

Parsowanie tekstu jest kluczowe w uzyskaniu potrzebnych informacji, do stworzenia materiałów naukowych na podstawie dostarczonych załączników.

Poniżej umieszczam schemat, przez który będzie przechodził tekst, który w późniejszych fazach trafi do RAG-A



Na początku tekst idzie do segmentacji. Segmentacja tekstu jest potrzebna do podziału długich treści na logiczne fragmenty, co ułatwia analizę, wyszukiwanie informacji i ich efektywne wykorzystanie. Dzieli je ze względu na tematykę, semantykę itp. Następnie podzielony tekst wchodzi do

bloku (programu) ekstrakcja kluczowych informacji. Ekstrakcja kluczowych informacji pozwala wydobyć najważniejsze dane z tekstu, co ułatwia ich szybkie przetwarzanie i wykorzystanie. Następnie tekst jest rozszerzany używając bazy danych Retrieval. Rozszerzenie kontekstu z bazy danych Retrieval pozwala na wzbogacenie odpowiedzi chatbota o precyzyjne i aktualne informacje.

Dzięki przepuszczeniu oryginalnego tekstu przez te 3 bloki uzyskamy lepszą, bardziej konkretną odpowiedź, która pozwoli uzyskać potrzebne nam informacje. Do tego dzięki wykorzystaniu LLM, będzie można w bardziej konkretny sposób określić, co ma się znaleźć w materiałach.

Każdy z poszczególnych bloków ma kilka swoich podejść:

1. Segmentacja tekstu

Podejście bezpośrednie – Model LLaMA analizuje tekst i dzieli go na sekcje w jednym kroku, wykrywając naturalne zmiany tematu.

Podejście iteracyjne – Najpierw model identyfikuje punkty podziału, a następnie generuje osobne sekcje z tytułami i opisami.

2. Ekstrakcja kluczowych informacji

Podójście bezpośrednie – Model generuje listę kluczowych informacji w jednym zapytaniu.

Podójście iteracyjne (rozbite na pytania) – Najpierw model identyfikuje kategorie istotnych danych, a następnie iteracyjnie wyciąga szczegółowe informacje.

3. Rozszerzenie kontekstu z bazy danych retrieval (RAG)

Podójście klasyczne (BM25) – Wyszukiwanie najbardziej pasujących fragmentów w bazie danych i ich dołączenie do prompta.

Podójście embeddingowe (FAISS, ANN) – Wyszukiwanie semantycznie podobnych dokumentów na podstawie osadzonych reprezentacji tekstu.

Podójście hybrydowe – Łączy BM25 i embeddingi, aby zwiększyć precyzję wyszukiwania.

W następnych krokach przetestuję każde podójście i wybiorę najlepsze w kontekście ChatBota PGVERSE